Goua Beedi

M2 MS2A | Machine Learning & AI Research

gouabeedi@gmail.com | LinkedIn | GitHub | Portfolio | Paris, France

Profil

Après une formation d'ingénieur en statistique et data science à l'ENSAI, je poursuis le M2 MS2A à Sorbonne Université. Mes expériences m'ont amené à développer des modèles, à comparer leurs performances sur des données réelles et à évaluer des systèmes d'IA. J'approfondis aujourd'hui les méthodes probabilistes, la simulation et les modèles génératifs, dans une perspective de recherche appliquée.

Formation

Sorbonne Université — Paris, France
Master 2 Mathématiques – Statistique, Apprentissage et Algorithmes (MS2A) — *2026–2027*

Cours pertinents – S1 (en cours) : apprentissage statistique, optimisation stochastique, statistique en grande dimension, data science en pratique (machine learning, deep learning, modèles génératifs) et méthodes de simulation (Monte Carlo, importance sampling, SMC, inférence variationnelle, VAE, flots normalisants et modèles de diffusion).

ENSAI – École Nationale de la Statistique et de l'Analyse de l'Information — Rennes, France
Formation d'ingénieur en statistique et data science — *2022–2025*

Cours pertinents : Deep Learning (PyTorch), apprentissage statistique à grande échelle, traitement automatique du langage (NLP), apprentissage par renforcement, probabilités et modèles de Markov, régularisation, optimisation numérique et séries temporelles.

Compétences

Machine Learning et Deep Learning : Python, PyTorch, scikit-learn, XGBoost, réseaux de neurones, régression, classification, régularisation et sélection de modèles.

Statistiques et modélisation : régression linéaire et GLM, probabilités, séries temporelles, inférence statistique, calibration et optimisation.

Simulation et modèles génératifs (formation et projet en cours) : Monte Carlo, importance sampling, SMC, inférence variationnelle, VAE et modèles de diffusion guidée.

Recherche et évaluation : conception de benchmarks, validation croisée par groupes, contrôle des fuites de données, comparaison de modèles, analyse d'erreurs et expérimentation reproductible.

NLP et ingénierie : RAG, embeddings, recherche d'information, RAGAS, ChromaDB, NumPy, pandas, SQL, R, Git, Docker et FastAPI.

Expériences

FINZUU – Fintech — Paris, France
Data Scientist – Scoring du risque de crédit agricole — *2026*

- Conception de traitements de scoring en Python à partir de données agricoles multi-sources pour estimer la production, les revenus et la capacité de remboursement.
- Construction d'indicateurs de risque interprétables, mise en place de contrôles de cohérence et intégration des traitements via FastAPI.

Square Management – Square Research Center — Paris, France
Stagiaire AI & Data Science – Évaluation de systèmes RAG — *2025*

- Conception et exécution d'un benchmark reproductible de **189 configurations RAG** sur documents longs, en faisant varier l'OCR, le découpage, les embeddings et les méthodes de recherche.
- Évaluation de la pertinence des résultats et de la fidélité des réponses aux sources ; analyse des écarts de performance et des principaux modes d'échec.
- Automatisation des évaluations avec des pipelines Python utilisant RAGAS, ChromaDB, FastAPI et Docker.

Ville de Paris – Agence de la Mobilité — Paris, France
Stagiaire Data Scientist – Analyse de données de mobilité — *2024*

- Rapprochement de données hétérogènes (LAPI, SIV, SIREN), contrôles de qualité et construction d'indicateurs statistiques pour l'analyse et la segmentation des flottes de véhicules.

Projets

Challenge ENS – Maladie de Parkinson
Challenge Data #159 – Projet individuel de Machine Learning, en cours — *2026*

- Modélisation de trajectoires longitudinales de patients à l'aide de réseaux de neurones et d'architectures Transformer, avec validation croisée séparant les patients pour prévenir les fuites d'information.
- Expérimentation de corrections temporelles, comparaison et combinaison de modèles, analyse des erreurs et étude de la cohérence des trajectoires prédites.

Modèles de diffusion et événements rares – MS2A
Projet de recherche de cours – DireSMC, en cours — *2026–2027*

- Étude du guidage de modèles de diffusion vers des événements rares par Sequential Monte Carlo (SMC), à partir de l'article *Steering Diffusion Models to Rare Events with Sequential Monte Carlo*. Travail orienté vers les méthodes d'échantillonnage et l'estimation de probabilités d'événements rares.

Credit Scoring – Banque LCL
Projet académique de Machine Learning — *2025*

- Modélisation du risque de défaut sur **530 000 comptes et 143 variables** ; comparaison de la régression logistique, Random Forest et XGBoost, avec sélection de variables, validation croisée et analyse de la calibration.

Langues

Français : courant | **Anglais :** professionnel